### Prueba Intertrimestral

Nombre: Jorge

Apellidos: González Cardelús Tiempo de la prueba: 2 Horas

Asignatura: Desarrollo de Aplicaciones para la Visualización de Datos

Fecha: 18 de octubre de 2023

#### Instrucciones:

- Escribe código limpio y autoexplicativo.
- Se eliminará 0.5 puntos por usar Seaborn o Matplotlib.
- Se pueden utilizar los materiales de clase.
- Se puede utilizar internet para búsqueda de dudas y documentación.
- No se puede utilizar ningún tipo de LLM.
- No se puede utilizar mensajería instantánea.
- Sube tus resultados a tu repositorio de Github.
- Imprime una versión en PDF en A3 y Portrait del notebook.
- Envialo tus resultados a dmartincorral@icai.comillas.edu adjuntando el PDF y la url del notebook subido al repositorio de Github.

### Inicialización de librerías

Carga aquí todas las librerías que vayas a utilizar.

```
import pandas as pd
import numpy as np
import plotly.graph_objects as go
from plotly.subplots import make_subplots
import plotly.express as px

from sklearn import datasets
from sklearn.linear_model import LinearRegression
from sklearn.ensemble import RandomForestRegressor
from sklearn.model_selection import train_test_split
from statsmodels.regression.linear_model import OLS
from sklearn.metrics import r2_score, mean_squared_error
```

## ▼ Ejercicio 1 (2 puntos):

- a) Crea una función que calcule y devuelva el factorial de un número entero. (0.6 puntos)
- b) Crea una función que verifique si un número es primo o no. (0.6 puntos)
- c) Muestra en un dataframe los 50 primeros números positivos, si es primo y su factorial utilizando las funciones anteriores. (0.6 puntos)
- d) ¿Cómo se podría programar en una clase las tres operaciones anteriores? (0.2 puntos)  $\,$

```
class Operations:
   def fact(self, n):
       if n == 0:
           return 1
        if n>1:
            return self.fact(n-1)*n
        elif n==1:
            return 1
    def is_prime(self, n):
        check = 2
        while check < n:
            if n % check == 0:
                # Es divisble entre check, no puede ser primo
                return False
            else:
                check += 1
        return True
   def create_dataframe(self, n=50):
        data = []
        for i in range(n):
            data.append([i, self.fact(i), self.is_prime(i)])
        df = pd.DataFrame(data, columns=["number", "factorial", "is_prime"])
        return df
operations = Operations()
operations_df = operations.create_dataframe(50)
operations_df.head(20)
```

	number	factorial	is_prime	$\blacksquare$
0	0	1	True	ıl.
1	1	1	True	
2	2	2	True	
3	3	6	True	
4	4	24	False	
5	5	120	True	
-	-			

## ▼ Ejercicio 2 (4 puntos):

- a) Extrae de sklearn el conjunto de datos California Housing dataset y transfórmalo a dataframe de pandas (0.25 puntos)
- b) Construye una función que muestra la estructura del dataset, el número de NAs, tipos de variables y estadísticas básicas de cada una de las variables. (0.5 puntos)
- c) Construye una Regresión lineal y un Random forest que predigan el Median house value según los datos disponibles. (0.75 puntos)
- d) Visualiza cuales son las variables (coeficientes) más importantes en cada uno de los modelos. (1.25 puntos)
- e) Decide a través de las métricas que consideres oportunas, cuál de los dos modelos es mejor, por qué y explica el proceso que has realizado para responder en los puntos anteriores. (1.25 puntos)

```
15    15    1307674368000    False
housing = datasets.fetch_california_housing()
print(housing.keys())
    dict_keys(['data', 'target', 'frame', 'target_names', 'feature_names', 'DESCR'])
housing_dataframe=pd.DataFrame(housing["data"], columns=housing["feature_names"])
housing_dataframe["target"] = housing["target"]
```

housing\_dataframe.head(5)

```
MedInc HouseAge AveRooms AveBedrms Population AveOccup Latitude Longitude target
                                                                                                    \blacksquare
8.3252
             41.0
                    6.984127
                                1.023810
                                                 322.0
                                                        2.555556
                                                                       37.88
                                                                                 -122.23
                                                                                           4.526
8.3014
             21.0
                    6.238137
                                0.971880
                                                2401.0
                                                        2.109842
                                                                       37.86
                                                                                 -122.22
                                                                                           3.585
7.2574
             52.0
                    8.288136
                                1.073446
                                                 496.0
                                                        2.802260
                                                                                 -122.24
                                                                                           3.521
                                                                       37.85
                                1.073059
5.6431
             52.0
                    5.817352
                                                 558.0
                                                        2.547945
                                                                       37.85
                                                                                 -122.25
                                                                                           3.413
3.8462
             52.0
                    6.281853
                                1.081081
                                                 565.0
                                                       2.181467
                                                                       37.85
                                                                                 -122.25
                                                                                           3.422
```

```
def describe_df(df):
    print("Dataframe information:\n\n")
    print(df.info())
    print("\n\nDataframe statistics:\n\n")
    print(df.describe())

print("\n\nNAs:\n\n")
    for column in df.columns:
        print(column + ": " + str(df[column].isna().sum()))
```

describe\_df(housing\_dataframe)

Dataframe information:

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 20640 entries, 0 to 20639
Data columns (total 9 columns):
                 Non-Null Count Dtype
    Column
 #
 0
     MedInc
                  20640 non-null
                  20640 non-null
     HouseAge
                  20640 non-null
     AveBedrms
                  20640 non-null
                                  float64
     Population
                 20640 non-null
                                  float64
     Ave0ccup
                  20640 non-null
                                  float64
                 20640 non-null
                                  float64
     Latitude
     Longitude
                 20640 non-null
                                  float64
8 target 20 dtypes: float64(9)
                 20640 non-null
                                  float64
memory usage: 1.4 MB
```

Dataframe statistics:

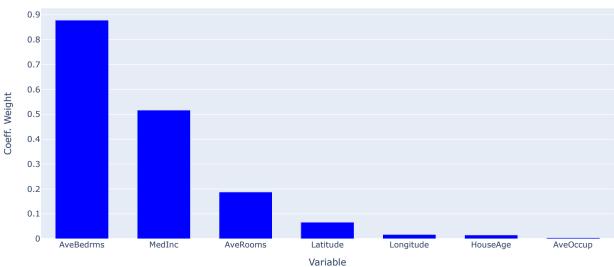
	MedInc	HouseAge	AveRooms	AveBedrms	Population	\
count	20640.000000	20640.000000	20640.000000	20640.000000	20640.000000	
mean	3.870671	28.639486	5.429000	1.096675	1425.476744	
std	1.899822	12.585558	2.474173	0.473911	1132.462122	
min	0.499900	1.000000	0.846154	0.333333	3.000000	
25%	2.563400	18.000000	4.440716	1.006079	787.000000	
50%	3.534800	29.000000	5.229129	1.048780	1166.000000	
75%	4.743250	37.000000	6.052381	1.099526	1725.000000	
max	15.000100	52.000000	141.909091	34.066667	35682.000000	
	Ave0ccup	Latitude	Longitude	target		
count	20640.000000	20640.000000	20640.000000	20640.000000		
mean	3.070655	35.631861	-119.569704	2.068558		
std	10.386050	2.135952	2.003532	1.153956		
min	0.692308	32.540000	-124.350000	0.149990		
25%	2.429741	33.930000	-121.800000	1.196000		
50%	2.818116	34.260000	-118.490000	1.797000		
75%	3.282261	37.710000	-118.010000	2.647250		
max	1243.333333	41.950000	-114.310000	5.000010		

NAs:

MedInc: 0 HouseAge: 0 AveRooms: 0 AveBedrms: 0 Population: 0 AveOccup: 0 Latitude: 0 Longitude: 0 target: 0 X = housing["data"]

c) Construye una Regresión lineal y un Random forest que predigan el Median house value según los datos disponibles. (0.75 puntos)

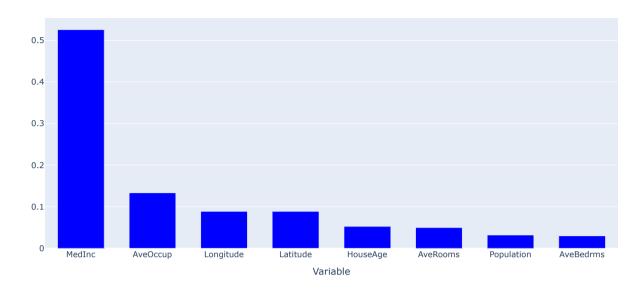
```
y = housing["target"]
X_{train}, X_{test}, y_{train}, y_{test} = train_test_split(X_{train}, Y_{test}), random_state = 123)
lr_{model} = OLS(y_{train}, X_{train})
rf_model = RandomForestRegressor()
lr result = lr model.fit()
rf_result = rf_model.fit(X_train, y_train)
d) Visualiza cuales son las variables (coeficientes) más importantes en cada uno de los modelos. (1.25 puntos)
lr_result.summary()
                            OLS Regression Results
                                      R-squared (uncentered): 0.893
       Dep. Variable: y
          Model:
                     OLS
                                     Adj. R-squared (uncentered): 0.893
         Method:
                     Least Squares
                                             F-statistic:
                                                               1.716e+04
                                          Prob (F-statistic):
           Date:
                     Wed, 18 Oct 2023
                                                               0.00
           Time:
                     17:22:12
                                          Log-Likelihood:
                                                               -19248.
     No. Observations: 16512
                                               AIC:
                                                               3.851e+04
       Df Residuals: 16504
                                                BIC:
                                                               3.857e+04
         Df Model: 8
      Covariance Type: nonrobust
         coef std err
                         t P>ltl [0.025 0.975]
     x1 0.5168 0.005 107.955 0.000 0.507
     x2 0.0153 0.001 29.508 0.000 0.014
     x3 -0.1879 0.007 -27.171 0.000 -0.201
                                           -0.174
     x4 0.8780 0.033 26.472 0.000 0.813
                                           0.943
     x5 5.02e-06 5.71e-06 0.879 0.380 -6.18e-06 1.62e-05
     x6 -0.0045 0.001 -7.845 0.000 -0.006 -0.003
     x7 -0.0665 0.004 -16.580 0.000 -0.074 -0.059
     x8 -0.0173  0.001  -13.550  0.000 -0.020  -0.015
        Omnibus: 3585.633 Durbin-Watson: 1.996
     Prob(Omnibus): 0.000 Jarque-Bera (JB): 12700.311
                                           0.00
         Skew:
                  1.070
                               Prob(JB):
                               Cond. No.
        Kurtosis: 6.726
                                           1.03e+04
     Notes:
     [1] R<sup>2</sup> is computed without centering (uncentered) since the model does not contain a constant.
     [2] Standard Errors assume that the covariance matrix of the errors is correctly specified.
     [3] The condition number is large, 1.03e+04. This might indicate that there are
     strong multicollinearity or other numerical problems
def plot_coeff_importance(df, title):
    coeff_importance_figure = go.Figure()
    feature_importance_trace = go.Bar(x=df["variable"], y=df["weight"], marker_color="blue", width=np.repeat(0.65, len(df[:])))
    coeff_importance_figure.add_trace(
         feature_importance_trace
    coeff_importance_figure.update_layout(title=title, xaxis_title="Variable", yaxis_title="Coeff. Weight")
    coeff_importance_figure.show()
lr_coeff_importance = pd.DataFrame()
lr_coeff_importance["variable"] = housing["feature_names"]
lr_coeff_importance["weight"] = abs(lr_result.params)
lr_coeff_importance["pvalue"] = lr_result.pvalues
lr_coeff_importance = lr_coeff_importance[lr_coeff_importance["pvalue"] < 0.05]</pre>
lr_coeff_importance = lr_coeff_importance.sort_values(by="weight", ascending=False)
lr_coeff_importance.head()
         variable weight
                                             \blacksquare
                                   pvalue
      3 AveBedrms 0.877981 2.883904e-151
            MedInc 0.516778 0.000000e+00
         AveRooms 0.187936 4.479569e-159
           Latitude 0.066454 3.042622e-61
         Longitude 0.017265 1.314939e-41
plot_coeff_importance(
    lr_coeff_importance,
     "Variable importance in Linear Regression model<br><sup>Ignores coeffs. with p-value > 0.05</sup>"
            Variable importance in Linear Regression model
            Ignores coeffs. with p-value > 0.05
            0.9
```



```
rf_coeff_importance = pd.DataFrame()
rf_coeff_importance["variable"] = housing["feature_names"]
rf_coeff_importance["weight"] = rf_model.feature_importances_
rf_coeff_importance = rf_coeff_importance.sort_values(by="weight", ascending=False)
rf_coeff_importance.head()
        variable weight
                            \blacksquare
          MedInc 0.525620
        AveOccup 0.133315
     5
        Longitude 0.088621
          Latitude 0.088566
     1 HouseAge 0.052345
```

plot\_coeff\_importance(rf\_coeff\_importance, "Variable importance in Random Forest model")

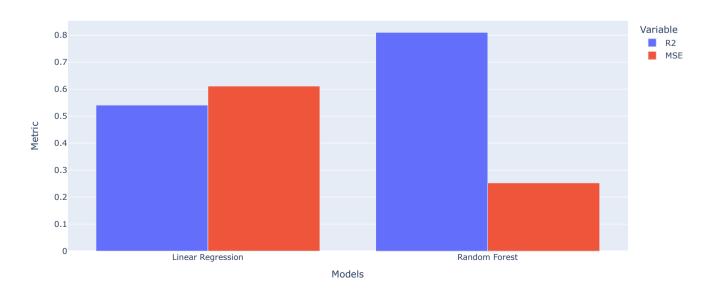
### Variable importance in Random Forest model



e) Decide a través de las métricas que consideres oportunas, cuál de los dos modelos es mejor, por qué y explica el proceso que has realizado para responder en los puntos anteriores. (1.25 puntos)

```
lr_predictions = lr_result.predict(X_test)
rf_predictions = rf_model.predict(X_test)
lr_r2 = r2_score(y_test, lr_predictions)
rf_r2 = r2_score(y_test, rf_predictions)
lr_mse = mean_squared_error(y_test, lr_predictions)
rf_mse = mean_squared_error(y_test, rf_predictions)
df_metrics = pd.DataFrame()
df_metrics["R2"] = [lr_r2, rf_r2]
df_metrics["MSE"] = [lr_mse, rf_mse]
df_metrics.index = ["Linear Regression", "Random Forest"]
fig = px.bar(
    df_metrics,
    barmode="group",
    title="Permformance Linear Regression vs. Random Forest",
    labels={
        "value": "Metric",
        "index": "Models",
        "variable": "Variable"
fig.show()
```

## Permformance Linear Regression vs. Random Forest



En el Random Forest el R2 es mayory el MSE es menor que en el modelo de Linear Regression, lo que lo hace un modelo superior.

# ▼ Ejercicio 3 (4 puntos):

Consideremos el dataset que contiene The Most Streamed Spotify Songs 2023 que se encuentra en el respositorio.

Información de las variables:

- track\_name: Name of the song
- artist(s)\_name: Name of the artist(s) of the song
- vartist\_count: Number of artists contributing to the song
- released\_year: Year when the song was released
- released\_month: Month when the song was released
- release\_day: Day of the month when the song was released
- in\_spotify\_playlists: Number of Spotify playlists the song is included in
- in\_spotify\_charts: Presence and rank of the song on Spotify charts
- streams: Total number of streams on Spotify
- in\_apple\_playlists: Number of Apple Music playlists the song is included in
- in\_apple\_charts: Presence and rank of the song on Apple Music charts
- in\_deezer\_playlists: Number of Deezer playlists the song is included in
- in\_deezer\_charts: Presence and rank of the song on Deezer charts
- in\_shazam\_charts: Presence and rank of the song on Shazam charts
- bpm: Beats per minute, a measure of song tempo
- · key: Key of the song
- mode: Mode of the song (major or minor)
- danceability\_%: Percentage indicating how suitable the song is for dancing
- valence\_%: Positivity of the song's musical content
- energy\_%: Perceived energy level of the song
- acousticness\_%: Amount of acoustic sound in the song
- instrumentalness\_%: Amount of instrumental content in the song
- liveness\_%: Presence of live performance elements
- speechiness\_%: Amount of spoken words in the song

Para las respuestas b, c, d, e, f y g es imperativo acompañarlas respuestas con una visualización.

- a) Lee el fichero en formato dataframe, aplica la función del ejercicio 2.b, elimina NAs y convierte a integer si fuera necesario. (0.25 puntos)
- b) ¿Cuántos artistas únicos hay? (0.25 puntos)
- c) ¿Cuál es la distribución de reproducciones? (0.5 puntos)

in\_deezer\_charts in\_shazam\_charts

76.000000

97.000000

748.000000

2.368984

5.316258

0.000000

0.000000

- d) ¿Existe una diferencia signitificativa en las reproducciones entre las canciones de un solo artista y las de más de uno? (0.5 puntos)
- e) ¿Cuáles son las propiedades de una canción que mejor correlan con el número de reproducciones de una canción? (0.5 puntos)
- f) ¿Cuáles son las variables que mejor predicen las canciones que están por encima el percentil 50? (1 puntos)

Nota: Crea una variable binaria (Hit/No Hit) en base a 3.c, crea una regresión logística y visualiza sus coeficientes.

g) Agrupa los 4 gráficos realizados en uno solo y haz una recomendación a un sello discográfico para producir un nuevo hit. (1 puntos)

bpm 748.000000

123.143048

28.333491

65.000000

100.000000

danceability\_% \

748.000000

67.592246

14.585603

23.000000

58.000000

0.000000

91.000000

24.000000

97.000000

```
spotify = pd.read_csv("./spotify-2023.csv", encoding="ISO-8859-1")
spotify["streams"] = pd.to_numeric(spotify["streams"], errors="coerce")
spotify["in_deezer_playlists"] = pd.to_numeric(spotify["in_deezer_playlists"], errors="coerce")
spotify["in_shazam_charts"] = pd.to_numeric(spotify["in_shazam_charts"], errors="coerce")
spotify = spotify.dropna()
describe_df(spotify)
```

23.0	0.00000		0.000000 100.000000			30.000	70.000000		
50%	0.000000 1.00000				70.000				
75%					.000000	79.000000			
max	45.000000		953.000000 206.000000		96.000000				
	valence_%	energy_%	acousticnes	S_%	instrume	entalness_%	liveness_%	\	
count	748.000000	748.000000	748.000	000		748.000000	748.000000		
mean	51.129679	64.137701	26.700	535		1.681818	18.304813		
std	23.607864	15.933631	25.190	809		8.838448	13.722069		
min	4.000000	14.000000	0.000	000		0.000000	3.000000		
25%	32.000000	53.000000	6.000	000		0.000000	10.000000		
50%	51.000000	65.000000	18.000	aaa		0.000000	12.000000		

41.250000

97.000000

748.000000

124.329225

48.909091

0.000000

0.000000

70.000000

97.000000

64.000000

## NAs:

max

count

mean

min

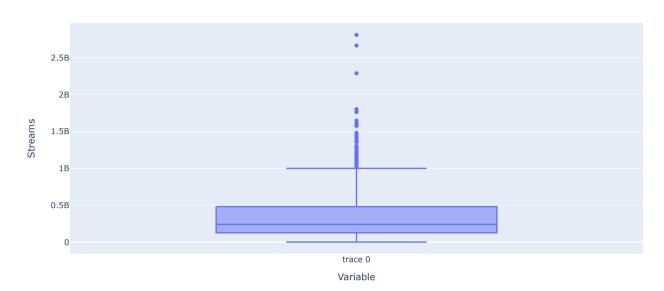
75%

max

```
track_name: 0
artist(s)_name: 0
artist_count: 0
released_year: 0
released month: 0
released_day: 0
in_spotify_playlists: 0
in_spotify_charts: 0
streams: 0
in_apple_playlists: 0
in_apple_charts: 0
in_deezer_playlists: 0
in deezer charts: 0
in_shazam_charts: 0
bpm: 0
key: 0
mode: 0
danceability_%: 0
valence_%: 0
energy_%: 0
acousticness_%: 0
instrumentalness_%: 0
liveness %: 0
speechiness %: 0
```

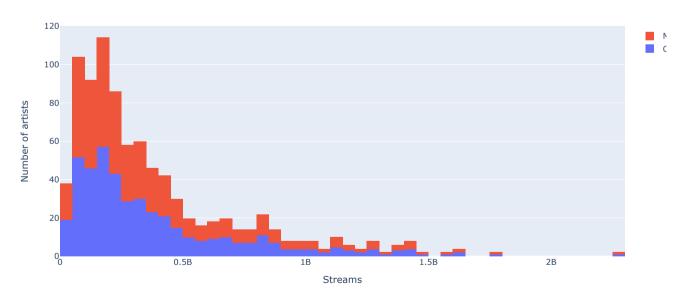
- b) ¿Cuántos artistas únicos hay? (0.25 puntos)
- c) ¿Cuál es la distribución de reproducciones? (0.5 puntos)

### Distribution of streams



## d) ¿Existe una diferencia signitificativa en las reproducciones entre las canciones de un solo artista y las de más de uno? (0.5 puntos)

## Distribuciones de artistas con ${\bf 1}$ canción vs. múltiples canciones



No hay una diferencia signficativa entre ambas

e) ¿Cuáles son las propiedades de una canción que mejor correlan con el número de reproducciones de una canción? (0.5 puntos)

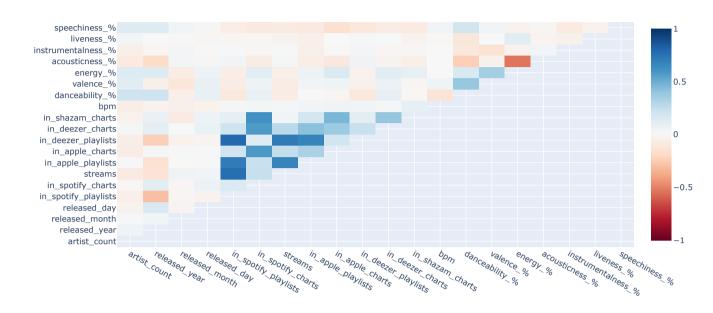
```
spotify_numbers = spotify.select_dtypes(include='number')
stream_corr = spotify_numbers[spotify_numbers.columns].corr()
stream_corr.head()
```

artist count released year released month released day in spotify playlists in spotify charts streams in apple playlists in apple charts in deezer playlist

```
mask = np.triu(np.ones_like(stream_corr, dtype=bool))

stream_corr_heatmap = go.Heatmap(
    z=stream_corr.mask(mask),
    x=stream_corr.columns,
    y=stream_corr.columns,
    colorscale=px.colors.diverging.RdBu,
    zmin=-1,
    zmax=1
)

corr_matrix = go.Figure(
    stream_corr_heatmap
)
corr_matrix.show()
```



The variables that most correlate with streams are:

- · In spotify playlists
- In apple playlists
- In apple charts
- · In spotify charts
- In deezer playlists
- In deezer charts

(The most near to 1, and -1 of the corr matrix)

f) ¿Cuáles son las variables que mejor predicen las canciones que están por encima el percentil 50? \*\*(1 puntos)

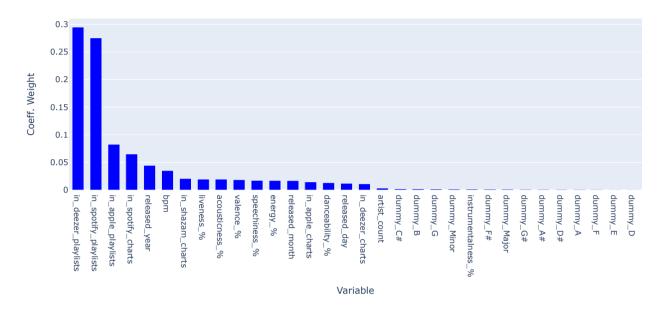
```
popular\_cutoff = spotify["streams"].quantile(q=0.5)
print(popular_cutoff)
popular_songs = spotify[spotify["streams"] > popular_cutoff]
popular_songs.size
    240844044.5
    8976
popular_songs.columns
    dtype='object')
# Remove un-dummiable variables
popular_songs_dataset = popular_songs.drop(["track_name", "artist(s)_name"], axis=1)
{\tt popular\_songs\_dataset.columns}
dummies = pd.get_dummies(popular_songs_dataset[["key", "mode"]], prefix="dummy")
popular_songs_dataset = popular_songs_dataset.drop(["key", "mode"], axis=1)
popular_songs_dataset = pd.concat([
   popular_songs_dataset,
    dummies
], axis=1)
x_variables = list(popular_songs_dataset.columns)
x_variables.remove("streams")
# Divide data in X,Y
X_popular_songs = popular_songs_dataset[x_variables]
y_popular_songs = popular_songs_dataset["streams"]
X_popular_songs.head()
```

	artist_count	released_year	released_month	released_day	in_spotify_playlists	in_spotify_charts	in_apple_playlists	in_apple_charts	in_deezer_playlists	in_deezer_charts .	
3	1	2019	8	23	7858	100	116	207	125.0	12	
4	1	2023	5	18	3133	50	84	133	87.0	15	
6	2	2023	3	16	3090	50	34	222	43.0	13	
9	2	2023	3	17	2953	44	49	110	66.0	13	
10	2	2023	4	17	2876	40	41	205	54.0	12	

5 rows  $\times$  32 columns

plot\_coeff\_importance(popular\_songs\_coeff\_importance, "Variable importance for songs with streams in the 50% percentile")

### Variable importance for songs with streams in the 50% percentile



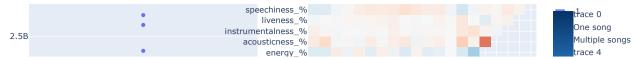
g) Agrupa los 4 gráficos realizados en uno solo y haz una recomendación a un sello discográfico para producir un nuevo hit. (1 puntos)

```
fig = make_subplots(rows=2, cols=2)

feature_importance_trace = go.Bar(
    x=popular_songs_coeff_importance["variable"],
    y=popular_songs_coeff_importance["weight"],
    marker_color="blue",
    width=np.repeat(0.65, len(popular_songs_coeff_importance[:]))
)

fig.add_trace(reproduction_distribution_trace, row=1, col=1)
fig.add_trace(stream_corr_heatmap, row=1, col=2)
fig.add_traces(song_count_traces, rows=2, cols=1)
fig.add_trace(feature_importance_trace, row=2, col=2)
fig.update_layout(width=1000, height=1000, bargap=0.1, title="Dash")
fig.show()
```

### Dash



El éxito de la canción está muy correlado con el hecho de que se publique en las principales plataformas (Deezer, Spotify, Apple).

También es importante que sea algo acústica, enérgica y que se pueda bailar.

Y no hay una diferencia significativa entre sacar una canción o sacar múltiples (en cuanto al número de reproducciones).

